

第 14 届“泰迪杯”数据挖掘挑战赛

B 题

上市公司财报“智能问数”助手

2026 年 4 月 17 日

摘要

针对上市公司财报”智能问数”任务，方案涵盖从非结构化 PDF 抽取到自然语言交互问答的完整链路，由数据抽取、智能查询与可靠性增强三个模块逐层递进。任务一设计了涵盖预处理、多策略抽取、标准化转换、跨表融合、数据校验、数据入库与质量评估七阶段的流水线，从 1235 份财报中提取 3290 条结构化记录；四张核心报表的平均字段覆盖率依次为 0.9327、0.8785、0.8017 和 0.9229，会计勾稽校验通过率为 94.65%。任务二构建端到端智能问数系统，以统一查询视图屏蔽多表关联的复杂度，将意图解析、Text2SQL[1]、SQL 自动纠错、图表规范渲染等环节显式编码为有限状态转移图；在 70 道测试题上，SQL 生成率达 97.1%，图表渲染成功率为 92.7%，多轮上下文继承成功率为 80.0%。任务三进一步设计基于检索增强生成（RAG）[2] 的可靠性增强框架，为复杂推理与归因溯源能力的扩展预留技术接口。

关键词：智能问答；Text2SQL；财报分析；数据抽取

目录

摘要	1
1 问题重述	1
1.1 问题背景	1
1.2 核心任务剖析	1
2 问题分析	1
2.1 任务一的分析	1
2.2 任务二的分析	2
2.3 任务三的分析	2
3 模型假设与符号说明	2
3.1 基本假设	2
3.2 符号说明	4
4 结构化财报数据库的构建	4
4.1 财报信息抽取问题的学术背景	4
4.2 任务一处理框架	5
4.2.1 总体设计思路	5
4.2.2 数据预处理	5
4.2.3 多策略报表抽取	6
4.2.4 字段映射与单位统一	6
4.2.5 候选结果融合与跨表补值	6
4.2.6 数据校验与入库	6
4.2.7 质量评估与结果交付	7
4.3 抽取结果与质量评估	7
4.4 误差分析	7
4.5 任务一的模型局限与改进方向	8
4.6 与后续任务的衔接	8
5 智能问数助手核心系统	9
5.1 问题分析与总体框架	9
5.2 能力一：自然语言解析与基础查询	9
5.2.1 统一查询视图	9
5.2.2 意图解析与查询规划	11
5.2.3 Text2SQL 与自闭环修复	11

5.2.4	案例验证：单轮比较查询与别名消解（B1003）	12
5.3	能力二：多轮对话与上下文继承	13
5.3.1	共享状态与查询要素继承	13
5.3.2	指代消解与状态更新	13
5.3.3	案例验证：多轮对话与上下文继承（B1045）	13
5.4	能力三：意图澄清与引导机制	14
5.4.1	查询要素完整性检查与澄清触发条件	14
5.4.2	追问策略与用户反馈融合	14
5.4.3	案例验证：语义歧义与意图澄清（B1007）	14
5.5	能力四：可视化图表的规范生成	15
5.5.1	图表需求识别与类型决策	15
5.5.2	三层图表架构与渲染失败兜底	15
5.5.3	案例验证：TopN 排名查询与图表输出（B1049）	16
5.6	系统集成测试与效果评估	16
5.6.1	量化评估结果	17
5.6.2	误差分析	17
5.7	任务二的模型局限与改进方向	18
5.8	与后续任务的衔接	18
6	可靠性增强设计	18
6.1	问题分析与总体框架	18
6.2	能力一：研报知识库的构建	19
6.2.1	研报元数据标准化	19
6.2.2	PDF 正文抽取与结构化切片	19
6.2.3	向量索引构建	19
6.2.4	案例验证：知识库构建效果	19
6.3	能力二：多意图自主规划与检索	21
6.3.1	复杂问题解析与意图路由	21
6.3.2	检索计划与混合检索模式	21
6.3.3	SQL 分支与检索分支的并行组织	21
6.3.4	案例验证：多意图规划（B2008）	22
6.4	能力三：归因分析与证据融合	22
6.4.1	证据重排机制	22
6.4.2	SQL 与证据融合	22
6.4.3	答案生成与结构化引用	22
6.4.4	自检校验机制	22
6.4.5	案例验证：归因分析与知识检索（B2003）	22
6.5	系统集成测试与效果评估	23

6.6	任务三的模型局限与改进方向	23
6.7	与总结展望的衔接	24
7	模型评价与改进	24
8	总结与展望	25
	附录	28

1 问题重述

1.1 问题背景

资本市场信息披露透明度持续提升，监管问询机制日趋规范，机构投资者对上市公司财务数据的实时洞察与深度挖掘需求随之增长。然而，现有投研数据处理模式面临效率瓶颈：传统依赖人工拆解 PDF 报表与常规 BI 工具的工作流耗时耗力，各环节信息割裂，难以支撑跨周期、多维度的关联分析。另一方面，若直接以通用 LLM 处理海量长文本财报，又极易导致算力冗余、响应延迟及事实性错误。因此，探索 LLM 与现代数据工程的深度融合，打通从底层非结构化财务披露文件到顶层自然语言交互的全链路，是金融科技领域亟待解决的核心问题。

1.2 核心任务剖析

赛题要求构建一款低门槛、高可靠的上市公司财报智能问数助手，完整覆盖自然语言输入、意图识别、SQL 生成、数据查询、可视化呈现与分析结论输出的全过程。整个工程可拆解为三个递进的核心任务：底层数据库构建、智能交互中枢开发、复杂推理能力增强。

任务一需从海量且排版异构的 PDF 财报中提取核心财务信息，经清洗与逻辑校验后规范化存储至关系型数据库。任务二依托结构化数据库构建支持多轮对话与自动化图表生成的 Text2SQL 智能体。任务三通过融合外部研报构建 RAG 机制，使系统具备复杂问题的多步拆解与归因溯源能力。

2 问题分析

赛题融合了复杂数据工程与大语言模型应用两方面的技术挑战。系统最终的查询准确率与稳定性，不仅取决于中枢大语言模型的推理能力，更取决于底层非结构化数据清洗的质量。

2.1 任务一的分析

任务一要求从上市公司财务报告 PDF 中提取关键财务数据，并按给定数据库结构完成入库。该任务本质上是面向复杂半结构化文档的结构化信息抽取问题，主要难点如下。

财务报告的版式差异显著。不同交易所、不同公司乃至不同年份的财报，在表头命名、单位表达、分页方式和续表形式上均存在较大差异，同一类指标可能以多种方式出现，给字段统一带来挑战。此外，目标报表并非始终处于固定页面，且经常出现跨页延续、标题拆行、数值换行等现象，导致单一表格抽取工具难以稳定适配。任务还要求完

成字段标准化、单位统一、数据校验和数据库入库，因此必须在抽取环节之后进一步设计结果融合与质量控制机制。

从任务依赖关系看，任务一是后续任务二和任务三的重要基础。任务二中的自然语言问数模块依赖于任务一输出的结构化财务数据库；任务三中的数据核验、归因分析和多源增强问答同样需要将财务数据作为核心证据来源。因此，任务一的目标不仅是抽取得到结果，更要构建一个结果稳定、结构统一、可追溯、可扩展的数据库。

基于上述考虑，任务一不宜采用单步骤、单工具的抽取方式，而是构建了一条由预处理、抽取、转换、融合、校验、评估组成的处理流程，以兼顾抽取准确率、结果一致性与后续应用可用性。

2.2 任务二的分析

任务二要求依托结构化财报数据库，开发一款具备多轮对话与自动化图表生成的自然语言问数助手。该任务本质上是面向结构化数据的 Text2SQL 与可视化生成的端到端智能体构建问题。核心难点至少有三处：多轮对话中的上下文漂移与指代消解——系统需准确继承前序轮次的公司集合、时间范围与查询结果；SQL 生成的语义正确性与安全性——LLM 直接生成 SQL 时容易出现字段名错误、量纲混淆乃至语法错误，且必须保证只读操作；可视化结果的可控性——通用 LLM 在选择图表类型时往往存在不可预测的偏差。为此，本文将对话全链路显式编码为有限状态机，把意图解析、查询计划、Text2SQL、自闭环修复、业务校验与图表规范渲染等环节抽象为状态节点与条件转移边，以提升系统的稳定性与可解释性。

2.3 任务三的分析

三个任务之间的数据依赖与技术演进关系如图 1 所示。任务一为整个系统提供结构化数据库；任务二在此基础上构建自然语言问数能力；任务三则通过引入外部研报知识，进一步增强系统的复杂推理与归因溯源能力。

3 模型假设与符号说明

为便于后续建模与推导，本文给出以下基本假设与符号约定。

3.1 基本假设

1. **数据源真实性假设**：所有输入的上市公司财务报告 PDF 文件均为监管机构公开发布的真实文档，不存在人为伪造或恶意篡改。
2. **版式可解析假设**：虽然不同公司、不同年份的财报在排版上存在差异，但四张核心报表（资产负债表、利润表、现金流量表、核心业绩指标表）均以表格或类表格




图 1 赛题任务分解与依赖关系图

形式呈现，且具备可识别的中文表头，能够通过规则或工具进行定位与抽取。

3. **会计准则一致性假设：**同一家公司在同一报告期内的各张报表遵循统一的会计口径与计量单位，报表间的主要财务指标满足基本的会计勾稽关系。
4. **查询意图有限性假设：**用户提出的自然语言问数请求主要围绕基础查询、趋势分析、对比分析、排名统计和比例结构五类意图，不涉及需要复杂跨库推理或实时外部市场数据（如股价、成交量）的问题。
5. **大语言模型能力假设：**所调用的大语言模型具备基本的中文语义理解、SQL 代码生成和数学计算能力，在提供清晰提示（Prompt）和错误反馈的情况下，能够完成 Text2SQL 转换与答案生成任务。

3.2 符号说明

本文涉及的主要符号及其含义如表 1 所示。

表 1 主要符号说明

符号	含义
$\mathcal{P}$	财报 PDF 文档集合
$\mathcal{T}$	结构化数据库中的表集合
$\mathcal{V}$	统一查询视图
q	用户输入的自然语言问句
$\mathcal{S}$	系统维护的共享状态对象
$\mathcal{M}$	大语言模型
s	查询要素向量（公司、时间、指标、意图）
s_k	第 k 次生成的 SQL 语句
R	SQL 执行后的结果集
$\mathcal{G}$	图表规划参数集合
k	检索增强中的 Top- k 召回数量
ε	异常值过滤阈值

4 结构化财报数据库的构建

4.1 财报信息抽取问题的学术背景

从非结构化或半结构化的 PDF 文档中提取表格信息，学术界已形成两条主要技术路线。基于规则与光学字符识别（OCR）的方法通过布局分析定位表格区域，再借助启

发式规则解析单元格之间的行列关系，在版式固定的场景中精度较高，但对文档格式的变化极为敏感，难以适应不同公司、不同年份财报之间的版式差异。基于深度学习的端到端文档理解方法，如 DocFormer、Nougat[19]、LayoutLM[3] 等预训练模型，能够对文档版面进行联合编码并直接输出结构化表格，在通用文档理解任务上表现优异，但通常需要大量标注数据进行微调，且对计算资源要求较高，在竞赛场景下的大规模批量处理中部署成本较大。

财务报告中的目标表格具有鲜明的领域特征：专业术语固定、跨页续表频繁、单位表达方式多样。完全依赖通用深度学习模型容易忽略这些先验约束，而纯规则方法又难以覆盖长尾版式。因此，本文选择了一条“规则主导、模型辅助、多策略融合”的折中路线：在预处理、表定位和字段映射阶段充分注入领域规则，在跨页续表识别和文本补充抽取阶段引入成熟的文档解析工具链，以兼顾准确率、稳定性与工程可行性。相关文档理解研究如 LayoutLM[3]、StructuralLM[4] 和表格检测工作 UTD[5] 也为本文的多策略融合思路提供了方法参考。

4.2 任务一处理框架

4.2.1 总体设计思路

设原始财报 PDF 集合为 $\mathcal{P}$ ，目标结构化表集合为 $\mathcal{T} = \{T_{\text{perf}}, T_{\text{bal}}, T_{\text{cf}}, T_{\text{inc}}\}$ ，分别对应核心业绩指标表、资产负债表、现金流量表和利润表。针对财务报告 PDF 结构复杂、版式差异显著及字段口径不统一等问题，本文构建了涵盖预处理、多策略抽取、标准化转换、跨表融合、数据校验、数据入库与质量评估七个阶段的处理框架，整体流程如图 2 所示。该框架以四张目标表为中心，依次完成表定位、字段抽取与结果入库，并在流水线末端输出质量评估结果与人工核验材料。



图 2 任务一数据处理流程图

4.2.2 数据预处理

数据预处理阶段旨在统一上交所与深交所财报目录的元数据规范。对于上交所数据，系统依据文件名解析股票代码、报告日期及随机标识，生成结构化清单；对于深交所数据，则进一步识别摘要、全文、更正后、更新后等版本后缀，并依据更正版优先原则完成版本归并。预处理后输出统一格式的清单文件，为后续批量抽取提供稳定的输入基准。

4.2.3 多策略报表抽取

抽取阶段采用多策略融合的方法。首先利用 PDF 解析引擎对页面进行扫描，并依据合并资产负债表、合并利润表、合并现金流量表、主要会计数据和财务指标等关键词定位目标报表的起始页。随后，针对跨页报表场景，使用文档级表格提取工具进行跨页表格抽取，以增强对财务报表续页结构的处理能力。

考虑到部分报表在 PDF 中无法以标准表格对象形式稳定提取，系统进一步引入文本补充抽取方案，对拆行标签和续行数值进行重构；在单页结构化表格场景下，则使用多路备用提取链路形成冗余保障。该多策略抽取设计使系统在不同版式条件下均保持较高的适应性。

4.2.4 字段映射与单位统一

抽取结果获得后，系统构建字段别名映射词典，将财报中的中文项目名统一映射至数据库标准字段，多种异名同义的表述被归并到同一目标字段。同时，对金额字段执行单位统一，将元、万元和亿元转换为统一尺度；对比例类字段则统一处理百分号、百分点、括号负数等特殊格式。字段映射与单位统一显著降低了版式差异对结构化结果一致性的影响。

4.2.5 候选结果融合与跨表补值

鉴于同一份财报可能从多个页面得到多条候选记录，系统按股票代码、报告期、报告年度和报表类型对候选结果分组，并优先保留字段更完整、来源更稳定的候选项。此外，系统进一步利用跨表关系执行补值与派生计算：由资产总计和负债合计推导所有者权益合计，由利润表和资产负债表结果补充核心业绩指标表中的毛利率、净利率、每股净资产和扣非 ROE 等字段。该机制显著提升了目标字段覆盖率，对核心业绩指标表的改善尤为明显。

4.2.6 数据校验与入库

在形成最终结构化记录后，系统对数据执行多层规则校验，并在入库前完成一致性处理。第一层为基础完整性校验，包括必填字段检查与业务主键重复检查，以保证同一公司、同一报告期、同一报表类型的记录具备可入库的关键元数据，避免出现主键缺失或重复写入。第二层为数值合理性校验，重点针对同比、环比、比例类字段执行异常值检测，以识别明显超出正常口径范围的可疑结果。第三层为勾稽一致性处理，利用报表间的逻辑关系对结果进行补全和修正：由经营、投资和筹资活动现金流净额合成净现金流，并进一步推导资产负债率和现金流占比等指标。

在数据库落地策略上，系统默认使用 SQLite 进行本地持久化，以方便调试与中间结果保留；同时支持通过传入 MySQL 连接串将结果直接写入 MySQL 数据库，以满足赛题数据库应用场景的要求。入库完成后，系统设计了独立的会计勾稽校验脚本，对数据

库内部逻辑进行二次验证，并输出通过率、失败率与失败样例，从而使入库前自动校验和入库后二次质检形成完整的质量控制链路。

4.2.7 质量评估与结果交付

为保证任务一结果的可解释性与可复核性，主流程末端设置了质量评估模块，可输出字段覆盖率统计、缺失字段频次分布、缺失原因分析、人工抽样核验模板以及论文结果表与文字稿。该设计使任务一不仅能够输出数据库结果，还能提供结果质量的量化描述与人工复核依据。

4.3 抽取结果与质量评估

为验证所提方法的有效性，在正式数据上进行了全量实验。经清洗与版本归并后，系统共有效处理 1235 份财务报告，形成 3290 条主记录。资产负债表、现金流量表、核心业绩指标表和利润表的记录数分别为 820、823、824 和 823 条，对应的平均字段覆盖率依次为 0.9327、0.8785、0.8017 和 0.9229。

资产负债表和利润表已达较高覆盖水平，现金流量表亦表现出较好的稳定性，说明多策略抽取与跨表补值机制能够有效应对标准财务报表中的多数版式变化。与开发初期相比，跨页表格抽取、文本补充抽取和候选结果融合显著提升了表尾项目、续页项目及拆行项目的识别效果。

校验结果显示，当前全量结果已无错误，仅剩 17 条警告，系统已经消除了主键缺失、关键元数据遗漏和整表落空等结构性问题。剩余告警主要集中在少量同比或比例字段的异常值，属于长尾版式差异带来的局部问题，不属于流程性失效。核心业绩指标表的平均覆盖率相对较低，进一步分析发现其主要缺失字段为 `net_profit_qoq_growth` 和 `operating_revenue_qoq_growth`，且缺失原因多被判定为源文档可能未披露，因此这类缺失具有一定客观性，并不能简单视为抽取失败。

数据库落地后，进一步执行了基于会计勾稽关系的二次复核。结果显示，共构建 11 条勾稽校验规则，形成 8021 个可判定样本，其中通过 7592 个、失败 429 个，整体通过率达到 94.65%。从规则分布看，资产负债平衡、资产负债率一致性、现金流占比一致性、净利率一致性和每股指标一致性均取得较高通过率；相对失败率较高的规则主要为现金流合计勾稽和 ROE 跨表一致性，当前系统在标准主表项目上的内部逻辑已基本稳定，长尾问题更多集中在少量跨表口径差异和现金流子项抽取偏差上。

综合来看，任务一处理框架能够较为稳定地完成从财务报告 PDF 到结构化数据库的转换，已具备为后续问数与增强分析任务提供数据支持的能力。

4.4 误差分析

当前方法虽已取得较高覆盖率，但仍存在少量误差来源。

少数长尾字段仍受财报版式差异影响。部分公司在合同负债、短期借款等字段上的布局与常见版式不同，或者字段被拆分到多行、多列，导致现有规则未能完全覆盖。部分可派生字段依赖于上游输入的完整性：每股经营现金流、每股净资产等指标需要同时具备现金流、净利润、股本或权益等基础字段，一旦其中任一字段缺失，则派生链条会受到影响。还有一些字段的缺失源于原文披露限制，与抽取算法无关——对于年度报告而言，季度环比类指标往往不是标准披露内容，因此这类字段缺失具有一定客观性。即使基础记录已经入库，仍可能存在少量跨表口径不完全一致的情况，系统额外设计了会计勾稽校验脚本，对总资产平衡、现金流合计和关键财务比率进行数据库级复核，以进一步识别潜在异常记录。

从当前结果看，任务一系统的主要误差已从早期的整体抽取不足转变为少量长尾字段与披露差异问题。结合数据库级勾稽校验结果，资产负债表和利润表的主体结构已基本稳定，当前最值得重点复核的方向应转向现金流量表子项的口径一致性以及核心业绩指标表与利润表、资产负债表之间的个别跨表比率差异。后续优化不应再集中于整体流程重构，而应聚焦于个别长尾字段规则补充、少量特殊版式适配以及人工抽样复核机制的完善，这样的优化方向更符合竞赛场景下的时间投入与性能收益平衡。

4.5 任务一的模型局限与改进方向

任务一框架在竞赛数据集上已展现出较高的字段覆盖率与勾稽一致性，但仍存在结构性局限与改进空间。

长尾字段的覆盖上限受限于规则枚举的完备性。当前字段映射与版式适配规则主要基于训练集中的常见版式构建，对于训练集中未出现的特殊排版或字段别名，系统仍可能出现漏抽。纯规则驱动的方法在泛化能力上存在天然瓶颈，未来可探索在规则后处理阶段引入轻量级的序列标注模型，对高方差字段进行自动补全。

跨页续表的识别精度对文档解析工具链的版本和参数较为敏感。PDF 解析引擎与表格提取工具在不同 PDF 生成器之间存在差异，导致部分跨页表格的边界识别出现偏移。后续可引入基于视觉的版面分析模块，以图像级表框检测辅助文本级表格提取，形成多模态融合策略。

当前数据增强与合成机制主要依赖跨表派生和数值推导，尚未引入外部知识库或行业模板进行字段补全。对于核心业绩指标表中部分季度环比字段的缺失，若能结合行业披露惯例进行合理推断，可进一步提升覆盖率，但需警惕由推断引入的伪精度风险。

任务一的后续优化应遵循“规则求精、模型补漏、知识辅助”的渐进路径，在不破坏现有稳定性的前提下逐步扩展对长尾场景的适应能力。

4.6 与后续任务的衔接

任务一完成后形成的四张结构化业务表，既是任务二自然语言问数的数据源，也是任务三中数据校验、归因分析和多源增强问答的财务证据基础。任务一的贡献不只在

抽取结果本身，还在于建立了一套可被后续任务复用的数据库；其结构化程度和数据质量，直接决定了后续系统整体性能的上限。

5 智能问数助手核心系统

5.1 问题分析与总体框架

任务二的核心目标是在结构化财报数据库之上，构建一个支持多轮对话与自动图表生成的自然语言问数助手。从技术视角看，这等价于一个面向结构化数据的 Text2SQL[6-7] 与可视化渲染相结合的端到端智能体构建问题。赛题对该任务的考查聚焦于四项能力：自然语言解析与基础查询、多轮对话、意图澄清与引导，以及可视化图表生成。

为实现上述复杂对话 workflows，本文采用 LangGraph 框架对交互链路进行显式状态机建模。LangGraph 是一种面向大语言模型应用的状态机编排工具，支持将对话流程抽象为状态节点与条件转移边，允许在节点间传递共享状态对象，并天然支持循环回边以实现局部反馈闭环。该特性与任务二中多轮对话、SQL 自闭环修复等需求高度契合。形式化地，设用户输入为自然语言问句 q ，对话历史为 $\mathcal{H}$ ，结构化数据库为 $\mathcal{D}$ 。系统的目标是在单轮或多轮交互后输出一个五元组 $(s, R, \mathcal{G}, a, \mathcal{S}^{(t+1)})$ ，其中 s 为生成的 SQL 语句， R 为查询结果集， $\mathcal{G}$ 为图表规划参数（若无需可视化为空）， a 为自然语言回答， $\mathcal{S}^{(t+1)}$ 为更新后的对话状态。整个交互链路被编码为有限状态机：每个状态节点承担单一职责，状态转移路径构成可解释的推理轨迹，执行失败时沿条件边回到修复节点形成局部反馈闭环。该设计受到 ReAct[18] 中推理与行动协同思想的启发，将语言模型的规划能力与确定性工具调用相结合。

单次对话在状态机中的运转逻辑如下：先进行意图解析并提取查询要素；若要素不完整，则触发澄清追问，补充后重新解析。随后进入查询规划、SQL 生成与执行阶段；若执行失败，则将错误信息回送模型修正并重试，最多迭代 $K = 3$ 次，仍失败则输出兜底答案。查询成功后，若问题含可视化需求，则经图表渲染后汇入答案生成，否则直接生成答案。最后输出中文回答并更新状态，进入下一轮对话。下文将按此映射关系，分节对每项能力的设计思路、实现方法与实验验证进行详细阐述。整体架构如图 3 所示。

5.2 能力一：自然语言解析与基础查询

自然语言解析及基础查询的目标是将用户的开放式中文问句可靠地映射为可在结构化数据库上执行的标准 SQL。这一能力围绕统一查询视图、意图解析、Text2SQL、SQL 执行与自闭环修复四个关键环节展开。

5.2.1 统一查询视图

任务一输出的数据库包含利润表、核心业绩指标表、资产负债表和现金流量表四张业务表。若直接要求大语言模型在这四张表上生成 SQL，模型必须同时完成两项判断：




图 3 任务二智能问数系统状态机架构

一是识别问题涉及哪些表，二是正确书写表间关联条件，这显著增加了出错概率。为规避这一问题，系统预先将四张表按股票代码、报告期和报告年度横向拼接为一张宽表视图 $\mathcal{V}$ 。如此一来，模型在生成 SQL 时仅需面对单一表结构，跨表关联的复杂性被完全屏蔽。

在这张宽表的构建过程中，系统进行了两项处理：一是对重复出现的同一指标执行去重合并；二是预计算若干常用派生指标，如研发费用占比：

$$\text{研发费用占比} = \frac{\text{研发费用}}{\text{营业总收入}} \times 100 \quad (1)$$

此外，系统设置了简单的异常值过滤规则：金额类字段超过 10^8 或比率类字段超过 1000 的数值会被标记为缺失，从而避免因 PDF 版式差异或单位错误导致的极端异常值混入查询结果。统一查询视图的设计直接服务于能力一，它将四表关联复杂度从模型视角完全屏蔽，仅暴露单表结构，显著降低了 Text2SQL 难度。

5.2.2 意图解析与查询规划

意图解析层从用户问句中提取查询要素向量 $\mathbf{s} = (c, t, m, i)$ ，其中 c 为公司集合， t 为时间范围， m 为财务指标， i 为查询意图。意图类型进一步细分为基础查询、比较查询、趋势查询、排名查询和统计分析五种。指标解析依赖预先构建的别名映射函数 ϕ ：例如，“收益率”被映射为 `roe`，“999”被解析为“华润三九”（股票代码 000999）。时间解析通过正则表达式同时识别绝对时间（如 2024FY、2025Q3）和相对时间（如“去年”“同期”），并将后者锚定到当前对话上下文或最新报告期。

查询规划层根据解析后的查询要素决定 SQL 的大致结构：是否需要排序、是否需要限制返回条数、是否需要聚合函数、是否需要分组等。该层并不直接生成完整 SQL，而是输出一个“查询骨架”，为后续的 Text2SQL 模块提供结构化引导。

5.2.3 Text2SQL 与自闭环修复

SQL 生成采用基于提示工程的大语言模型方案 [8]。提示由三部分组成：数据库结构描述（仅包含视图 $\mathcal{V}$ 的字段列表与数据类型）、查询要素向量 $\mathbf{s}$ ，以及输出格式要求（要求生成标准 SQLite SQL，禁止使用未知字段和嵌套子查询）。借鉴 PICARD[9] 的约束解码思想，系统进一步在提示中显式限定字段白名单与 SQL 语法子集，以降低模型幻觉风险。此外，受 DIN-SQL[14] 分解式提示策略的启发，系统将复杂查询拆解为模式链接、查询分类与 SQL 生成三个子步骤，以提升大语言模型在上下文学习场景下的生成稳定性。此外，针对复杂跨域查询，本文参考了基于中间表示的 Text2SQL 方法 [10]，在查询规划阶段预先输出查询骨架，为 SQL 生成提供结构化引导。

查询执行模块将生成的 SQL 提交给数据库引擎执行。若执行成功，结果集被写入共享状态；若执行失败（语法错误、字段不存在、类型不匹配等），系统进入错误修复节点。修复节点将原始 SQL 与数据库返回的错误信息一并回送模型，要求其修正后重新

生成。该局部反馈闭环形式化为

$$s_{k+1} = \text{Repair}(s_k, e_k), \quad (2)$$

其中 s_k 为第 k 次生成的 SQL 语句， e_k 为对应错误信息，最多迭代 $K = 3$ 次。若 3 次修复均失败，则转入异常处理节点，输出包含错误说明的兜底答案。自闭环修复机制是能力一的关键保障，它将 SQL 生成率从“一次性生成”提升为“可迭代修正”，显著增强了基础查询的可靠性。

5.2.4 案例验证：单轮比较查询与别名消解 (B1003)

以下案例展示能力一中的意图解析、别名映射与图表渲染的完整链路。用户输入的问题为：“999 与白云山相比，去年收益率最高的是”。系统解析后识别出公司集合 {华润三九, 白云山}、报告期 2024FY、指标 roe，并将意图判定为比较查询。据此生成的 SQL 如下所示。查询结果显示，华润三九 (000999) 2024 财年 ROE 为 17.33%，显著高于白云山的 7.99%。系统据此生成柱状图并给出明确结论（图 4）。

```
1 SELECT stock_code, stock_abbr, report_period, roe
2 FROM financials_view
3 WHERE stock_abbr IN ('华润三九', '白云山')
4    AND report_period = '2024FY'
5 ORDER BY roe DESC;
```

该案例集中体现了能力一的两项关键设计效果：一是别名映射函数成功将“999”消解为“华润三九”，验证了意图解析层的实体识别能力；二是从自然语言问句到可执行 SQL 的完整转换在单轮内即告完成，验证了统一查询视图与 Text2SQL 机制的有效性。




图 4 B1003 系统输出结果——华润三九与白云山 ROE 对比柱状图

5.3 能力二：多轮对话与上下文继承

多轮对话能力的关键在于保持连续轮次之间的上下文一致性，避免用户重复输入前面已提及的公司、时间或指标。共享状态设计、查询要素继承规则与指代消解机制共同支撑了这一能力。相关研究如 CoSQL[11] 也为跨域对话式 Text2SQL 提供了重要的基准与方法参考。

5.3.1 共享状态与查询要素继承

系统维护跨轮次的共享状态对象 $\mathcal{S}^{(t)}$ ，包含当前问题、历史对话序列、查询要素向量、SQL 语句、查询结果、图表类型等字段。状态机在各节点间自动传递该对象，使下游节点可访问上游节点的全部输出。

查询要素继承规则定义了当前轮次解析结果与前序轮次状态之间的合并方式，具体分为三类。合并：当要素类型为集合时（如公司集合、时间集合），当前轮次的新增要素追加到已有集合中。覆盖：当用户明确更改某一要素时（如第二轮说“换成白云山”），新值直接替换旧值。继承：当当前轮次未提及某一要素时，前序轮次的该要素保持不变。这些规则使多轮对话中的查询要素能够动态演化，既不会遗漏历史信息，也不会被错误覆盖。

5.3.2 指代消解与状态更新

指代消解层负责处理问句中的代词和省略表达，如“这家公司”“同期”“去年”“和前面一样”等。具体策略包括：将“这家公司”解析为上一轮的公司实体；将“同期”解析为与上一轮相同的时间粒度（若上一轮是季度，则“同期”指同季度不同年度）；将“去年”相对于当前对话中的最新报告期进行偏移计算（如最新为 2025Q3，则“去年”指 2024Q3）。

状态更新在每轮回答输出后执行，将本轮的最终查询要素、SQL、结果和图表信息写入共享状态，为下一轮对话做好准备。该步骤是多轮对话能够持续进行的关键，对应状态机中从输出节点回到意图解析节点的循环回边。

5.3.3 案例验证：多轮对话与上下文继承（B1045）

以 B1045 为例，可观察能力二中的查询要素继承、指代消解与查询深化能力。用户以三轮对话依次询问：“云南白药 2022–2025 年第三季度的资产负债率变化趋势”；“这个趋势和白云山的同期变化趋势对比，差异在哪里”；“导致两者差异的核心财务指标（如负债总额、资产总额）变化是什么”。

第一轮系统解析公司为云南白药、报告期集合 $\{2022Q3, 2023Q3, 2024Q3, 2025Q3\}$ 、指标 `asset_liability_ratio`，生成趋势折线图。第二轮通过指代消解继承第一轮的公司实体云南白药，并新增对比公司白云山，“同期”被解析为与第一轮相同的季度集合，生成双公司同期对比 SQL。第三轮进一步继承两家公司集合，追加查询负债总额与资产

总额，最终从资产负债结构角度解释差异成因。三轮 SQL 均成功执行，输出了折线图与柱状图。

该案例完整展示了能力二的设计效果：第二轮无需重复指定云南白药和时间粒度，仅通过“这个趋势”“同期”等指代即可继承上下文；第三轮在公司集合继承的基础上追加新指标，实现了查询的逐轮深化。多轮状态继承的连续成功，验证了共享状态设计与查询要素继承规则的稳定性。

5.4 能力三：意图澄清与引导机制

意图澄清与引导机制负责处理查询要素缺失或语义歧义的情形。当系统无法从用户问句中提取完整的查询要素时，它会主动发起追问；若存在默认解析规则，也可先给出基于该规则的初步结果，以引导用户补充信息，进而提升后续查询的准确性。

5.4.1 查询要素完整性检查与澄清触发条件

查询要素完整性检查由函数 $\chi(\mathbf{s}) \in \{0, 1\}$ 控制，发生在意图解析之后。系统检查查询要素向量 $\mathbf{s} = (c, t, m, i)$ 中的四项是否均已提取到有效值。若任一要素为空，或某一意图类型所需的必填要素缺失（如排名查询缺少 TopN 数值），则触发澄清流程，即 $\chi(\mathbf{s}) = 0$ 。

除信息缺失型歧义外，系统还处理语义歧义型问题。当同一自然语言表达可映射到多个指标时（如“营收”可能指营业总收入、营业收入或主营业务收入），意图解析层会记录候选列表。若候选数量超过阈值，系统同样进入澄清节点，向用户列出可选指标并请其确认。

5.4.2 追问策略与用户反馈融合

追问策略采用“一次性列出所有缺失要素”的方式：系统在一次回复中告知用户当前缺少哪些信息，并给出示例，以减少交互轮次。例如，当用户问“去年的利润率是多少”而未指定公司时，系统回复：“请补充您想查询的公司名称，例如：云南白药、白云山等。”

用户补充的信息通过自然语言回复返回后，系统将其与新一轮用户问题拼接，重新送入意图解析层。解析时同时考虑原始问题与用户补充说明，更新共享状态中的查询要素向量。该闭环对应状态机中从澄清节点回到意图解析节点的追问回环。

5.4.3 案例验证：语义歧义与意图澄清（B1007）

B1007 集中检验能力三中对语义歧义的识别、澄清触发与用户反馈融合能力。用户以两轮对话依次询问：“哪些企业是亏钱的？”以及“亏钱指经审计财务报表的核心利润指标为负的数据。”

第一轮问题“亏钱”存在语义歧义。系统基于默认规则将其映射为净利润字段小于 0，返回了所有报告期内净利润为负的 30 家企业名单，并生成折线图。第二轮用户给出明确的业务定义后，系统确认该定义与默认映射一致（均指向净利润小于 0），但按最新报告期（2025Q3）重新筛选，输出 12 家亏损企业的柱状图与精确列表。

该案例展示了能力三的两个层面：一是当用户输入存在语义不确定性时，系统能够基于默认规则给出初步回答，同时隐含地引导用户进一步明确定义；二是当用户补充业务规则后，系统能够将该规则融入后续查询要素，修正筛选条件并输出更精确的结果。意图澄清机制避免了系统在歧义场景下的盲目猜测，提升了回答的可控性与用户满意度。

5.5 能力四：可视化图表的规范生成

图表生成是任务二的另一项关键能力。赛题中超过四分之三的测试题要求输出图表，其稳定性与规范性直接影响端到端表现。本文采用“三层图表架构”，将可视化过程从语义规划到确定性渲染逐层拆解，避免大语言模型直接生成绘图代码带来的不可控性。

5.5.1 图表需求识别与类型决策

图表规划层首先判断当前问题是否需要输出图表。判断依据包括：问题中是否包含显式的图表请求词（如“用图展示”“画个图”“可视化”）、是否包含隐含的图表场景词（如“趋势”“对比”“排名”）。若判断为需要图表，则进一步由图表类型决策函数 $\gamma(q)$ 确定输出类型：

$$\gamma(q) \in \{\text{Line}, \text{Bar}, \text{Pie}\}.$$

具体而言，趋势类问题（含“变化”“走势”等词）输出折线图（Line）；对比类与排名类问题输出柱状图（Bar）；占比类问题（含“占比”“结构”等词）输出饼图（Pie）。类型决策以规则为主、模型为辅，确保输出可预期、可解释。

5.5.2 三层图表架构与渲染失败兜底

三层图表架构的具体内容如下。语义规划层根据问题语义和查询结果结构，确定图表类型、坐标轴含义、数据系列划分方式。技术规范层将语义规划转化为确定性的参数规范（如坐标轴刻度、标签、图例位置等），该规范由模板代码生成，不依赖模型直接写绘图脚本。确定性渲染层调用标准可视化库按技术规范层输出的参数执行确定性渲染，生成图像并保存。

该架构的核心价值在于将大语言模型的作用范围限制在“语义规划”，而将“技术实现”与“最终渲染”交给确定性代码完成，避免了模型在绘图代码中引入语法错误、字段幻觉或样式不一致的问题。

当底层数据库返回空值或数据量不足时，渲染模块会触发失败兜底机制，系统不再尝试渲染图表，而是降级为输出结构化数据列表，确保用户至少能获得查询结果的文字形式。这一兜底机制使图表渲染成功率保持在较高水平。

5.5.3 案例验证：TopN 排名查询与图表输出（B1049）

以下以 B1049 为例，说明能力四在图表需求识别、类型决策与确定性渲染中的实际效果。用户问题为：“查询 2025 年第三季度 66 家中药公司营业总收入排名前十的公司，用条形图展示排名。”

系统解析得到报告期 2025Q3、指标为营业总收入、TopN 为 10、图表请求类型为柱状图。生成的 SQL 为：

```
1 SELECT stock_code, stock_abbr, total_operating_revenue
2 FROM financials_view
3 WHERE report_period = '2025Q3'
4 ORDER BY total_operating_revenue DESC
5 LIMIT 10;
```

执行结果返回白云山（616.06 亿元）、云南白药（306.54 亿元）等前十家公司。图表规划层判定为排名对比场景，输出柱状图技术规范；确定性渲染层生成如图 5 所示的排名柱状图，同时以结构化列表形式输出完整排名数据。

该案例完整验证了能力四的设计效果：从问题中的“条形图展示”和“排名前十”准确识别出图表需求与类型，经三层架构规范生成图像，最终图表与数据列表同时呈现，既满足了用户的可视化需求，也保留了精确的数据依据。




图 5 B1049 系统输出结果——2025Q3 营业总收入前十公司排名柱状图

5.6 系统集成测试与效果评估

为验证上述四项能力的实际效果，实验基于附件 4 中的 70 道测试题开展全量测试。数据库采用任务一输出的结构化财报库，包含 1235 份财报、3290 条主记录。系统输出保存于 result_2.xlsx，下文量化指标均来源于该实际运行结果。

5.6.1 量化评估结果

由于赛题未提供标准答案集，系统采用运营稳定性指标与按能力维度的成功率进行评估。表 2 给出了按四大能力维度统计的核心指标。

表 2 任务二系统按能力维度统计的核心指标（ $N = 70$ ）

能力维度	评估指标	数值	说明
能力一：自然语言解析与基础查询	SQL 生成率	68/70 (97.1%)	生成可执行 SQL 的题目比例
能力二：多轮对话与上下文继承	多轮上下文继承成功率	12/15 (80.0%)	多轮题最终获得有效回答的比例
能力三：意图澄清与引导机制	澄清触发覆盖率	8/8 (100%)	含缺失/歧义要素的题目中触发澄清的比例
能力四：可视化图表的规范生成	图表渲染成功率	51/55 (92.7%)	含图表请求且成功输出图像的比例
综合	端到端有效回答率	58/70 (82.9%)	未出现空结果、异常或 SQL 缺失的比例

能力一的 SQL 生成率达到 97.1% (68/70)，仅有两道题 (B1057、B1068) 因语义过于抽象而失败，说明统一查询视图与自闭环修复机制在主流查询场景下已具备较高稳健性。能力二的多轮上下文继承成功率为 80.0% (12/15)，共享状态设计与查询要素继承规则的效果得到了验证。能力三的澄清触发覆盖率为 100% (8/8)，系统对要素缺失或语义歧义场景无漏检。能力四的图表渲染成功率为 92.7% (51/55)，未成功渲染的 4 道题 (B1014、B1020、B1048、B1065) 均因底层数据库返回空值而触发兜底机制，系统未发生崩溃。综合来看，端到端有效回答率为 82.9% (58/70)。

5.6.2 误差分析

对 12 道未获得有效回答的题目进行溯源分析后发现，绝大多数失败并非源于任务二核心算法本身，而是受限于任务一数据库的覆盖范围。具体而言，10 道题（约占失败题目的 83.3%）因数据库缺少特定报告期或长尾字段而返回空值，涉及研发费用、环比增长率、扣非 ROE、未分配利润和出口业务占比等字段。另有 2 道题 (B1057、B1068) 因问题语义过于抽象——如“分析中药行业的盈利能力”或“分析营业总收入与净利润的相关性”——超出了预设查询要素体系，导致意图解析失败。由此可见，当前系统的薄弱环节高度集中于上游数据覆盖与少数极端语义场景，核心对话流程与 SQL 生成机制本身表现稳健。

后续优化可分为两个层次：在短期内，提升任务一的字段覆盖率、补充特定报告期数据即可将端到端有效回答率从 82.9% 提升至 97% 以上；在长期工程化落地层面，则可进一步探索意图解析器的轻量化扩展、SQL 执行计划的预编译缓存，以及面向更大规模数据集的并发查询架构设计，从而在保持现有准确率优势的同时提升系统的实时性与可扩展性。

5.7 任务二的模型局限与改进方向

任务二系统在标准查询和主流多轮对话场景中表现出较高的稳定性，但仍存在局限与改进空间。

意图解析层对极端简略的追问存在漏检风险。当用户输入仅包含单个指标名或模糊的时间指代（如“呢”“上个月呢”）时，查询要素提取的置信度会显著下降，可能导致错误的上下文继承或计划偏离，直接影响能力二与能力三的稳定性的。

当任务一数据库存在时间粒度缺口时，多轮对话可能放大不一致性。例如，第一轮查询了包含 2025Q3 的多个季度数据，第二轮追问“去年呢”时，若数据库中缺少 2024 年同期数据，系统生成的 SQL 虽语法正确但返回空值，容易给用户造成理解偏差，这属于能力一与能力二之间的衔接风险。

当前系统每轮对话均调用大语言模型完成意图解析、SQL 生成和答案生成，响应时延主要受限于外部接口的调用次数。在工程化部署层面，可通过引入轻量化的本地查询要素提取模型、SQL 缓存机制以及并行图表渲染来进一步优化响应效率。短期内优先提升任务一的数据覆盖率和报告期完整性；中长期可探索意图解析器的轻量化扩展、SQL 执行计划的预编译缓存，以及面向更大规模数据集的并发查询架构设计。

5.8 与后续任务的衔接

任务二输出的结构化查询结果、生成的 SQL 语句以及图表渲染结果，都可直接作为任务三复杂推理与归因溯源的数据证据。检索增强节点可以引用任务二的查询结果，与外部研报知识进行融合；任务二状态机中的异常分支（如 SQL 执行失败、查询结果为空）也能直接触发任务三的反思模块，启动问题重述与知识检索回路。因此，任务二的核心价值不仅在于完成自然语言到结构化查询的转换，更在于为上层增强推理任务构建了一个稳定、可解释、可复用的数据获取管道。

6 可靠性增强设计

6.1 问题分析与总体框架

任务二的核心能力限于结构化数据的 Text2SQL 查询。然而，真实财务问答往往同时依赖结构化指标与非结构化文本证据。例如，归因类问题“为什么某公司在行业下行时毛利率反而上升”既需要查询毛利率数据，也需要研报中的成本端定性解释。为弥合结构化数据与定性知识之间的鸿沟，任务三引入检索增强生成（Retrieval-Augmented Generation, RAG）技术。RAG 通过在大型语言模型生成回答之前，先从外部知识库中检索与问题相关的文本片段，并将检索结果作为上下文注入生成过程，从而扩展模型的知识边界、降低幻觉风险并增强答案的可追溯性 [2]。近期研究进一步指出，通过在生成过程中引入自适应检索与自我反思机制（如 Self-RAG[15]），可在保持答案流畅性的同时

显著提升事实准确性。在本系统中，外部知识源为赛题提供的上市公司研报集合，RAG 机制负责从中召回与问题语义相关的段落，作为结构化查询结果的补充证据。

任务三的目标是在用户问题、结构化数据库与外部研报集合的基础上，生成带有明确证据支撑的答案，其实现依赖于查询、检索与生成的复合映射。

如图 6 所示，任务三的设计围绕三项能力展开：外部研报到可检索向量知识库的构建；用户意图解析、查询路径规划与结构化查询和知识检索的协调；多源证据融合、生成校验与带结构化引用的最终答案输出。下文将依次阐述每项能力的实现机制与验证结果。

6.2 能力一：研报知识库的构建

6.2.1 研报元数据标准化

系统首先对研报的元数据字段执行规范化映射，建立统一的属性空间。每份研报的标准化元属性包括股票代码、公司名称、所属行业、发布日期、研究机构与评级，从而为后续跨源关联与范围过滤提供一致的索引键。

6.2.2 PDF 正文抽取与结构化切片

系统通过切片算子将每份研报的正文分解为若干语义单元。每个切片携带结构化元信息，包括所属章节、起始页码、结束页码、内容类型与关联图表。内容类型分为正文、图表标题与元数据三类。切片策略遵循“标题段落优先、图表标题优先、超长文本滑窗补充”的分层原则，以保证中文内容在后续检索中的可控性与语义完整性。

6.2.3 向量索引构建

对每个语义切片，系统调用嵌入模型生成稠密向量表示，并建立向量索引。检索时，通过归一化内积计算查询问题与切片的语义相似度。该稠密向量检索机制借鉴了 DPR[13] 中的双编码器架构思想，而 RAPTOR[16] 所提出的层次化语义组织方式也为后续在大规模研报集合上进行多粒度检索提供了扩展思路。为应对大规模嵌入计算，系统采用分批处理与断点续建机制，以确保知识库构建过程的可恢复性。

6.2.4 案例验证：知识库构建效果

实验数据集包含约 60,711 个有效切片，总字符规模约 670–700 万。其中主体类型为正文段落，图表标题类切片有效保留了视觉语义，仅不足 2% 的切片因原始文档信息缺失而回退为纯元数据。向量索引构建过程中，断点续建机制在异常中断场景下验证通过。上述结果表明，所构建的研报知识库在规模、结构与可靠性方面均满足后续检索增强的需求。主要参数配置汇总于表 3。




图 6 任务三可靠性增强整体架构

表 3 研报知识库构建核心参数

参数类别	参数名称	参数值
切片策略	单块最大字符数	900
	滑窗重叠字符数	150
嵌入模型	向量维度	1024
向量库	相似度度量	归一化内积（等价余弦相似度）
知识库规模	切片总数	60,711
	有效字符总量	约 670–700 万

6.3 能力二：多意图自主规划与检索

6.3.1 复杂问题解析与意图路由

任务三的解析层继承任务二的对话状态，并在此基础上扩展意图路由能力。根据问题的结构化需求强度，系统将用户意图划分为四类：纯结构化查询（SQL）、纯研报检索（RAG）、混合查询（Hybrid）和澄清（Clarify）。系统通过二元决策标志 $(\delta_{\text{SQL}}, \delta_{\text{RAG}}) \in \{0, 1\}^2$ 控制后续分支：当 SQL 标志为 1 时进入结构化查询链路；当 RAG 标志为 1 时进入研报证据检索链路；两者皆为 1 时触发融合回答。该设计使系统能够根据问题的结构化需求强度自主选择执行路径，与 WebGPT[12] 中工具调用与检索协同的思想一脉相承。

6.3.2 检索计划与混合检索模式

检索范围依据问题中的公司名、行业名或宏观比较类词汇过滤研报子集。在向量索引上执行 Top- k 语义召回后，为兼顾精确匹配与语义泛化，混合检索得分定义为 metadata 得分与向量得分的加权融合：

$$s_{\text{hybrid}}(q, c) = \alpha \cdot s_{\text{meta}}(q, c) + (1 - \alpha) \cdot s_{\text{vec}}(q, c),$$

其中 $\alpha \in [0, 1]$ 为可配置权重。召回后的证据集合再经重排模块筛选，最终保留 Top- k 片段供下游融合。

6.3.3 SQL 分支与检索分支的并行组织

系统通过条件分支协调 SQL 链路 with 检索链路的执行时序。当 SQL 标志为 1 时，先生成并执行结构化查询，将结果汇入融合节点；当 SQL 标志为 0 时，直接跳过 SQL 链路。SQL 分支保留与任务二一致的自闭环修复机制：执行失败后将错误信息回送模型修正，最多迭代 3 次，仍失败则输出兜底说明。该条件分支的组织方式保证了主流程的稳定性与可解释性。

6.3.4 案例验证：多意图规划（B2008）

测试题 B2008 要求“对比分析 2025 年第三季度毛利率高于 30% 的中药公司，结合研报说明其竞争优势”。系统解析后判定该问题为混合意图，即同时需要结构化数据与研报证据。具体而言，SQL 分支用于筛选满足毛利率阈值的公司集合；RAG 分支在个股研报范围内召回与“竞争优势”相关的定性片段。经混合检索与重排后，系统召回 Top-5 证据，并在融合节点将 SQL 结果与证据集合一并输入生成模块，输出兼具量化数据与深度分析的综合回答。该案例验证了多意图自主规划机制对筛选/对比类复杂问题的支撑能力。

6.4 能力三：归因分析与证据融合

6.4.1 证据重排机制

初始召回的证据集合经重排模块处理后，依据相关性和信息增益排序，剔除冗余片段。若重排模块异常，系统自动回退至基于检索得分的排序结果，以保证归因分析流程的连续性。

6.4.2 SQL 与证据融合

融合节点将结构化查询结果与重排后的证据合并为统一的回答上下文。该上下文同时包含量化财务结论与研报中的定性解释，为最终答案的生成提供完整的事实与归因依据。

6.4.3 答案生成与结构化引用

生成模块基于融合上下文输出中文回答。为增强可追溯性，每条证据均输出结构化引用元组，标明来源路径、起止页码及关联图表。输出阶段经过去重处理，防止同一片段被重复引用。

6.4.4 自检校验机制

系统通过一致性校验核查回答中的财务数字是否与 SQL 结果一致、归因观点是否均有证据支撑。若校验模块因异常未能完成，系统标记为跳过，不阻断最终导出流程。

6.4.5 案例验证：归因分析与知识检索（B2003）

测试题 B2003 包含两轮对话。第一轮询问华润三九 2022–2025 年第三季度营业总收入趋势，系统生成 SQL 并返回数据，渲染为折线图。第二轮追问“造成这种变化的主要原因”，系统识别为归因分析意图并触发混合检索。检索范围锁定该公司个股研报，召回片段中提及产品矩阵扩张、核心品种提价、渠道改革等定性因素。经重排后，最相

关的 Top-5 证据与 SQL 结果融合，生成带结构化引用的中文归因回答；自检模块确认财务数字与查询结果一致、归因观点均有研报支撑。该案例完整展示了从趋势查询到归因分析的闭环能力。

6.5 系统集成测试与效果评估

为验证任务三框架的有效性，本节报告小样本端到端测试结果。实验以大规模语言模型为中枢生成器，文本嵌入维度为 1024，向量索引基于精确内积检索构建。研报知识库经抽取、切片与分批嵌入后，共生成约 60,711 个有效切片，总字符规模约 670–700 万。

B2002、B2003、B2005、B2008 四道测试题均成功跑通意图解析、检索计划、SQL 生成/执行、研报证据召回、重排融合与答案生成的完整流程，主链通过率为 4/4。默认采用混合检索模式，每题召回 Top-5 证据片段供融合与归因。系统输出保存于 `result_3.xlsx`，表 4 汇总了核心性能指标。

表 4 任务三系统核心性能指标

指标	数值	说明
研报切片总数	60,711	个股与行业研报经结构化切片后的有效切块数
向量索引构建方式	精确内积检索	向量经归一化后等价于余弦相似度
小样本回答主链通过率	4/4	B2002、B2003、B2005、B2008 四题端到端跑通
检索模式	混合检索	metadata 加权打分与语义向量召回融合
默认召回数量	Top-5	每题默认召回 5 条证据片段供融合与归因

当前系统仍存在一些不足。澄清门控对筛选对比类题目存在过度触发风险；SQL 结果与研报证据的融合质量仍在调优，偶发观点与数据匹配不够紧密；任务三的可视化链路尚未正式接入；结构化引用的精度也还有提升空间。

6.6 任务三的模型局限与改进方向

任务三框架虽已验证端到端可行性，但在检索粒度、数据覆盖与多模态融合方面仍有局限。当前切片以段落级为主，顶部证据质量在复杂查询场景下仍有波动，后续可引入专门的精排模型优化证据排序。现有指标别名映射对部分相近财务术语的区分度不

足，存在语义混淆风险。任务三尚未接入图表渲染链路，归因分析结果缺乏配套可视化支撑。

后续改进包括：引入基于深度学习的精排器提升顶部证据相关性；借鉴 CRAG[17] 中的检索纠错思想，在证据召回阶段引入动态评估与重检索机制；评估不同嵌入模型在财务领域语义检索中的适配效果；将图表渲染链路接入任务三主链，实现数据趋势与研报观点的联合可视化；优化澄清门控的触发阈值，降低筛选对比类问题的误触发率。

6.7 与总结展望的衔接

任务三扩展了“智能问数”系统的边界，使其具备归因分析与外部知识增强的能力。结构化财务数据与外部研报证据的融合，让系统能够处理需要多步推理与定性解释的复杂问题。任务三输出的结构化引用与带证据支撑的中文回答，为最终分析结论与投资建议提供了可验证、可追溯的知识来源，数据查询与知识推理由此连接起来，形成完整的分析链路。

7 模型评价与改进

表 5 汇总了任务一与任务二的核心性能指标。

表 5 系统核心性能指标汇总

指标	数值	说明
财报处理数量	1235 份 / 3290 条记录	任务一全量输出
平均字段覆盖率	0.9327 / 0.8785 / 0.8017 / 0.9229	四张核心报表
会计勾稽校验通过率	94.65%	任务一二次质检
SQL 生成率	97.1% (68/70)	任务二测试集
图表渲染成功率	92.7% (51/55)	任务二测试集
多轮上下文继承成功率	80.0% (12/15)	任务二测试集
端到端有效回答率	82.9% (58/70)	任务二测试集

任务一的主体结构已基本稳定，当前优化重点应转向现金流量表子项的口径一致性与核心业绩指标表的跨表比率差异。任务二的端到端有效回答率主要受限于上游数据覆盖——约 83.3% 的失败题目因数据库缺少特定报告期或长尾字段而返回空值，核心对话与 SQL 生成机制本身表现稳健。任务三已完成 RAG 扩展框架设计，但尚未进行全量实验验证，后续工程实现重点在于向量检索策略优化与反思节点触发阈值调参。

8 总结与展望

所构建的方案形成了一条从非结构化 PDF 抽取到结构化数据库、再到自然语言交互问答的完整链路，涵盖数据抽取、智能查询与可靠性增强三个模块。任务一设计了涵盖预处理、多策略抽取、标准化转换、跨表融合、数据校验与质量评估七阶段的处理框架，从 1235 份财报中提取 3290 条结构化记录，四张核心报表的平均字段覆盖率依次为 0.9327、0.8785、0.8017 和 0.9229，会计勾稽校验通过率达 94.65%，为后续任务奠定了数据基础。任务二将对话全链路显式编码为有限状态机，把意图解析、Text2SQL、SQL 自动纠错、图表规范渲染等环节抽象为状态节点与条件转移边，在 70 道测试题上实现了 97.1% 的 SQL 生成率、92.7% 的图表渲染成功率、80.0% 的多轮上下文继承成功率与 82.9% 的端到端有效回答率。任务三设计了基于 RAG 的可靠性增强框架，通过检索节点与反思节点为复杂推理与归因溯源能力的扩展预留了接口。

后续工作可从三条主线推进。第一条主线着眼于任务一的长尾字段覆盖与跨页表格识别，探索规则与轻量模型的融合策略。第二条主线关注任务二的响应效率与多轮对话稳定性，尝试引入本地意图解析模型与 SQL 缓存机制。第三条主线则聚焦任务三 RAG 检索节点与反思模块的工程实现与消融验证，最终形成兼具准确性、可解释性与实时性的财报智能问数系统。

参考文献

- [1] LI J, HUI B, QU G, et al. Can LLM already serve as a database interface? A big bench for large-scale database grounded text-to-sqls[C]//Advances in Neural Information Processing Systems. 2024, 36.
- [2] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.
- [3] HUANG Y, LV T, CUI L, et al. LayoutLMv3: Pre-training for document AI with unified text and image masking[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 4083-4091.
- [4] LI Y, QIAN Y, YU Y, et al. StructuralLM: Structural pre-training for form understanding[C]//Proceedings of the 29th ACM International Conference on Multimedia. 2021: 373-381.
- [5] ZHONG X, SHAFIEE S V A, BORJI A. UTD: Table detection in document images with a multi-task approach[C]//Proceedings of the 2019 ACM Symposium on Document Engineering. 2019: 1-4.
- [6] YU T, ZHANG R, YANG K, et al. Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 3911-3921.
- [7] LI J, HUI B, QU G, et al. BIRD: A big benchmark for large-scale database grounded text-to-sql task[C]//International Conference on Learning Representations. 2024.
- [8] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [9] SCHOLAK T, SCHUCHER N, BAHDANAU D. PICARD: Parsing incrementally for constrained auto-regressive decoding from language models[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 9895-9901.
- [10] GUO D, TANG D, DUAN N, et al. Towards complex text-to-SQL in cross-domain database with intermediate representation[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 4524-4535.

- [11] YU T, ZHANG R, POLOZOV A, et al. CoSQL: A conversational text-to-SQL challenge towards cross-domain natural language interfaces to databases[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 1962-1979.
- [12] NAKANO R, HILTON J, BALAJI S, et al. WebGPT: Browser-assisted question-answering with human feedback[EB/OL]. (2021-12-17)[2026-04-17]. Available: <http://arxiv.org/abs/2112.09332>.
- [13] KARPUKHIN V, OGUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. 2020: 6769-6781.
- [14] POURREZA M, RAFIEI D. DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction[C]//Advances in Neural Information Processing Systems. 2023, 36.
- [15] ASAI A, WU Z, WANG Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[C]//The Twelfth International Conference on Learning Representations. 2024.
- [16] SARTHI P, ABDULLAH S, TULI A, et al. RAPTOR: Recursive abstractive processing for tree-organized retrieval[C]//The Twelfth International Conference on Learning Representations. 2024.
- [17] YAN S Q, GU J C, ZHU Y, et al. Corrective retrieval augmented generation[J]. arXiv preprint arXiv:2401.15884, 2024.
- [18] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models[C]//The Eleventh International Conference on Learning Representations. 2023.
- [19] BLECHER L, CUCURULL G, SCIALOM T, et al. Nougat: Neural optical understanding for academic documents[J]. arXiv preprint arXiv:2308.13418, 2023.

附录

附录 A：任务一字段映射与报表定位规则（节选）

Listing 1 任务一字段映射规则 (mappings.py)

```

1 TABLE_KEYWORDS = {
2     "core_performance_indicators_sheet": [
3         "主要会计数据", "主要财务指标",
4         "主要会计数据和财务指标", "主要财务数据",
5     ],
6     "balance_sheet": ["资产负债表", "合并资产负债表"],
7     "cash_flow_sheet": ["现金流量表", "合并现金流量表"],
8     "income_sheet": ["利润表", "合并利润表"],
9 }
10
11 FIELD_ALIASES = {
12     "core_performance_indicators_sheet": {
13         "营业收入": "total_operating_revenue",
14         "营业总收入": "total_operating_revenue",
15         "营业总收入同比增长": "operating_revenue_yoy_growth",
16         "归属于上市公司股东的净利润": "net_profit_10k_yuan",
17         "每股净资产": "net_asset_per_share",
18         "净资产收益率": "roe",
19         "加权平均净资产收益率": "roe",
20         # ... (更多别名映射)
21     },
22     # ... (其余三表类似)
23 }
```

附录 B：任务二有限状态机构建

任务二的对话控制链路被抽象为一个有限状态机。全局状态 S 在各节点间共享，包含用户当前输入、历史对话上下文、解析出的查询要素、SQL 语句及其执行结果、图表规划与渲染结果等信息。状态转移规则如下：

- (1) **意图解析**：接收用户自然语言输入，提取时间范围、目标公司、财务指标及问题类型，更新状态 S 中的查询要素；
- (2) **澄清判断**：若查询要素缺失或存在歧义，则转移至 **答案生成** 节点并返回澄清引导语；否则转移至 **查询规划** 节点；

- (3) **查询规划**: 根据查询要素与数据库模式, 构建 SQL 执行计划, 确定涉及的表与字段;
- (4) **SQL 生成**: 基于查询计划生成可执行的 SQL 语句并写入状态 S ;
- (5) **SQL 执行**: 在结构化数据库中执行 SQL。若执行失败且当前重试次数小于阈值, 则返回 **SQL 生成** 节点进行自动纠错; 若失败且重试次数已达上限, 则转移至 **答案生成** 节点报告错误; 若执行成功, 则转移至 **图表规划** 节点;
- (6) **图表规划**: 判断问题是否要求可视化输出。若是, 则生成图表配置 (类型、坐标轴、数据映射) 并转移至 **图表渲染** 节点; 若否, 则直接转移至 **答案生成** 节点;
- (7) **图表渲染**: 依据图表配置调用可视化组件生成图片, 将图片路径写入状态 S , 随后转移至 **答案生成** 节点;
- (8) **答案生成**: 整合 SQL 结果、图表路径及上下文信息, 生成自然语言回答;
- (9) **结果追加**: 将本轮回答追加至历史上下文, 更新对话状态;
- (10) **结果导出**: 将最终回答与相关中间结果持久化, 状态机终止。

上述状态转移关系亦可归纳为表 6 所示的形式。

表 6 任务二有限状态机主要状态转移表

序号	当前状态	下一状态 (条件)
1	开始	→ 意图解析
2	意图解析	→ 澄清判断
3	澄清判断	→ 答案生成 (需澄清) → 查询规划 (无需澄清)
4	查询规划	→ SQL 生成
5	SQL 生成	→ SQL 执行
6	SQL 执行	→ SQL 生成 (执行失败且重试未满足) → 答案生成 (执行失败且重试已尽) → 图表规划 (执行成功)
7	图表规划	→ 图表渲染 (需可视化) → 答案生成 (无需可视化)
8	图表渲染	→ 答案生成
9	答案生成	→ 结果追加
10	结果追加	→ 结果导出
11	结果导出	终止

附录 C：运行环境说明

本系统实验环境配置如下：操作系统为 macOS 14, Python 版本为 3.11, 主要依赖包包括 PDF 解析引擎、文档级表格提取工具、数据分析库、对象关系映射库、状态机编排库以及标准可视化库。大语言模型通过云端 API 调用实现。所有实验均在本地笔记本电脑上完成，无特殊 GPU 加速需求。